

Self-Supervised Modulation Classification under Varying SNR

변화하는 SNR 환경에서의 자기지도 변조 분류

Junha Woo [(School of Electrical Engineering, Korea University, Seoul, Korea), (jerry229@korea.ac.kr)]

초록

본 연구는 BPSK, QPSK, 8PSK, 16QAM, 64QAM 의 5 가지 변조 방식을 대상으로, 학습 데이터의 라벨이 매우 적은 상황에서 supervised learning(SL)과 contrastive self-supervised learning(SSL)을 비교한다. 실험에서는 AWGN 채널을 통해 synthetic I/Q 신호를 생성하고, -10 dB 부터 20 dB 까지의 다양한 SNR 조건에서 모델을 평가하여 SNR 변화에 따른 저라벨 변조 분류 성능을 분석하였다. 실험 결과, -10 dB 와 -5 dB 의 severe low-SNR 영역에서는 잡음 전력이 신호 구조를 압도하여 변조별 constellation 및 I/Q pattern 의 구분 가능성이 크게 낮아졌고, 대부분의 모델이 20% chance level 근처에 머물렀다. 반면 0-5 dB 의 transition 구간과 10-20 dB 의 비교적 높은 SNR 구간에서는 변조별 신호 구조가 관측 가능해지면서 contrastive SSL 이 SL 보다 더 높은 성능을 보였다. 이러한 결과는 contrastive SSL 이 저라벨 변조 분류에서 효과적인 label-efficient representation 을 제공하지만, 그 이득은 신호 구조가 관측 가능한 SNR 영역에서 주로 나타난다는 점을 보여준다.

Keywords: modulation classification, contrastive learning, SNR, low-label learning, synthetic I/Q

1. 서론

무선 신호의 변조 분류는 수신된 I/Q 신호로부터 변조 방식을 자동으로 판별하는 문제로, spectrum monitoring, cognitive radio, interference analysis 와 같은 다양한 무선 통신 응용에서 중요한 역할을 한다. 최근에는 deep learning 기반 방법이 raw I/Q sequence 로부터 변조별 특징을 학습할 수 있음이 보고되었으며 [1], 이는 automatic modulation classification 문제에서 데이터 기반 feature learning 의 가능성을 보여준다.

그러나 실제 무선 환경에서는 충분한 라벨을 가진 신호 데이터를 확보하기 어렵다. 라벨링에는 수집 환경, 송신 파라미터, 채널 조건에 대한 정보가 필요하며, 특히 SNR 이 낮은 조건에서는 변조별 신호 구조가 잡음에 의해 흐려져 라벨 기반 학습의 효율이 떨어질 수 있다. 이러한 문제를 완화하기 위해, 라벨 없이 입력 데이터의 구조를 먼저 학습한 뒤 적은 수의 라벨로 downstream task 를 수행하는 self-supervised learning 이 주목받고 있다. 특히 contrastive learning 은 서로 다른 augmentation view 사이의 표현을 가깝게 만들고 다른 샘플의 표현과는 구분되도록 학습함으로써, label-efficient representation learning 에 효과적인 방법으로 사용되어 왔다 [2], [3].

본 연구는 이러한 contrastive SSL 이 저라벨 변조 분류에서 언제 효과적인지를 SNR regime 관점에서 분석한다. 이를 위해 동일한 residual 1D CNN backbone 을 사용하는 SL baseline 과 contrastive SSL pretraining 기반 fine-tuning 모델을 비교하고, dense SNR sweep 을 통해 severe low-SNR, transition SNR, high-SNR 영역에서의 성능 차이를 평가한다.

본 논문의 구성은 다음과 같다. 2 장에서는 synthetic AWGN 기반 변조 분류 실험 환경과 SNR 및 label ratio 설정을 설명한다. 3 장에서는 SL baseline 과 contrastive SSL 모델이

공유하는 residual 1D CNN backbone, 학습 절차, augmentation 및 contrastive objective 를 제시한다. 4 장에서는 SNR 별 성능 결과를 분석하고, severe low-SNR 영역에서의 한계와 SSL 이 유리하게 작동하는 SNR 구간을 논의한다. 마지막으로 5 장에서는 본 연구의 결론과 향후 연구 방향을 정리한다.

2. 실험 설정

표 1. Synthetic AWGN 변조 분류를 위한 전체 실험 설정.

항목	설정
Task	5-class modulation classification
Modulations	BPSK, QPSK, 8PSK, 16QAM, 64QAM
Input	2 x 4096 I/Q samples
Main comparison	SL baseline vs contrastive SSL pretrain + fine-tune
Low-label ratios	0.0025, 0.005, 0.01
Dense test SNR	-10, -5, 0, 1, 2, 3, 4, 5, 10, 15, 20 dB
Chance level	20%

데이터는 synthetic I/Q 기반이며, 현재 결과는 AWGN channel 중심의 SNR 변화에 초점을 둔다. 본 연구에서는 channel coding/decoding, carrier frequency offset(CFO), timing offset, fading, IQ imbalance 와 같은 실제 RF 환경의 추가 impairments 를 실험 범위에서 제외하였다. 이는 본 연구의 목적이 실제 무선 채널 전체를 완전하게 재현하는 것이 아니라, AWGN 기반 SNR 변화가 SL 과 contrastive SSL 의 저라벨 변조 분류 성능에 미치는 영향을 분리하여 분석하는 데 있기 때문이다. 따라서 추가적인 채널 왜곡 요인을 배제함으로써

SNR 을 주요 통제 변수로 설정하고, SSL representation 이 어느 SNR regime 에서 유효한지를 명확하게 관찰하고자 하였다.

3. 모델 구조와 학습 방법

SL 과 SSL fine-tuning 은 같은 residual 1D CNN backbone 을 공유한다. Residual 1D CNN 은 간단한 구조이지만 I/Q sequence 의 시간축 방향 local pattern 을 convolution 연산으로 직접 처리할 수 있으며, residual connection 을 통해 깊은 feature 학습 과정에서 gradient 흐름을 안정화할 수 있다. 또한 두 학습 방식이 동일한 backbone 을 사용하도록 설계함으로써, 성능 차이가 모델 구조나 파라미터 수의 차이가 아니라 supervised training 과 contrastive SSL pretraining 방식의 차이에서 기인하도록 비교 조건을 통제하였다. Backbone 은 4 개의 residual block 으로 구성되며 채널 수는 2->64->128->256->512 로 증가한다. 각 block 은 Conv1d(kernel=3, padding=1), BatchNorm, ReLU, Conv1d, BatchNorm 과 shortcut connection 을 포함한다.

A. SimCLR-style SSL Pretraining




그림 1. SimCLR-style SSL pretraining 절차.

B. Shared 1D ResNet Encoder




그림 2. 공통 1D ResNet encoder 구조.

C. Fine-tuning and SNR-aware Heads




그림 3. Fine-tuning 및 SNR-aware per-head classifier 구조.

표 2. 공통 residual 1D CNN backbone 및 fine-tuning 구성.

구성 요소	구현 세부
Encoder	4 residual Conv1d blocks, channels 2/64/128/256/512, MaxPool after each block
Projection head	Linear(512*256 -> 512), ReLU, Linear(512 -> 128)
SSL classifier	Pretrained encoder features + Dropout(0.5) + Linear(512*256 -> 5)
SL classifier	Same backbone trained from scratch + Linear(512*256 -> 5)
Pretrain optimizer	Adam, lr=5e-4, batch size=16, 100 epochs
Fine-tune optimizer	Adam, encoder lr=1e-5, classifier lr=2e-4, weight decay=1e-4, batch size=16, 200 epochs

3.1 Contrastive objective 와 augmentation

SSL pretraining 은 SimCLR-style NT-Xent loss 를 사용한다. 같은 원본 신호에서 독립적으로 augmentation 한 두 view 를 positive pair 로 두고, batch 내 다른 sample 의 view 를 negative 로 사용한다. 본 연구에서 사용한 augmentation 은 신호의 본질적인 변조 구조를 유지하면서 amplitude, phase, noise level 등 관측 조건의 변화를 반영하도록 설계하였다. 이를 통해 모델은 특정 라벨에 직접 의존하지 않고도 변조 분류에 유용한 representation 을 사전에 학습할 수 있다. 이후 fine-tuning 단계에서는 pretrained encoder 에 classification head 를 결합하고, 제한된 수의 labeled samples 를 사용하여 downstream modulation classification 을 수행한다.

$$\mathcal{L}_i = -\log \frac{\exp(\text{sim}(z_i, z_j)/\tau)}{\sum_{k \neq i} \exp(\text{sim}(z_i, z_k)/\tau)}, \quad \tau = 0.5$$

여기서 z_i 와 z_j 는 같은 원본 신호에서 생성된 두 augmented view 의 projection 이고, $\text{sim}(\cdot, \cdot)$ 은 cosine similarity 이다. 분모는

anchor i 를 제외한 batch 내 다른 view 들을 negative 로 포함하며, temperature τ 는 0.5 로 설정하였다.

표 3. Contrastive pretraining 및 fine-tuning 에 사용한 augmentation 설정.

Augmentation	세부값
Amplitude scaling	$p=0.8$, scale $\sim \text{Uniform}(0.5, 1.5)$
Phase rotation	$p=0.6$, angle $\sim \text{Uniform}(0, 2\pi)$
AWGN perturbation	$p=0.8$, additive noise sigma=0.01
Fine-tune scaling	$p=0.5$, scale $\sim \text{Uniform}(0.95, 1.05)$
Fine-tune AWGN	$p=0.5$, additive noise sigma=0.001

주의할 점은 phase rotation 증강이 과하면 역효과를 불러올 수 있다는 것이다. 이는 carrier phase 변화에 대한 불변성을 학습시키는 장점이 있지만, PSK/QAM 계열에서 위상 구조가 변조 식별에 중요한 경우 모델이 배울 위상 정보를 약화시킬 가능성도 있다. 따라서 severe low-SNR 에서 noise 와 augmentation 이 함께 구분 정보를 흐리는 문제가 발생할 수 있다.

4. 결과 및 분석

본 장에서는 SNR 변화에 따른 SL baseline 과 contrastive SSL 기반 모델의 변조 분류 성능을 비교한다. 결과는 SNR regime 에 따라 SSL 의 효과가 크게 달라짐을 보여준다. 특히 severe low-SNR 영역에서는 잡음으로 인해 변조별 신호 구조가 충분히 관측되지 않아 SL 과 SSL 모두 chance level 에 가까운 성능을 보였으나, transition 및 high-SNR 영역에서는 SSL pretraining 을 통해 학습된 representation 이 적은 라벨 조건에서 더 높은 분류 성능으로 이어졌다.




그림 4. Label ratio 0.005 에서의 dense SNR 평가 결과.

표 4. Label ratio 와 SNR 영역별 SL/SSL 평균 정확도 및 성능 향상.

Ratio	SNR 영역	SL	SSL	Gain
0.0025	severe -10,-5	20.02	19.64	-0.38
0.0025	transition 0-5	20.25	34.91	+14.65
0.0025	high 10-20	28.67	78.19	+49.52
0.005	severe -10,-5	20.06	19.78	-0.28
0.005	transition 0-5	25.21	39.76	+14.55
0.005	high 10-20	42.85	77.48	+34.63
0.01	severe -10,-5	19.64	20.34	+0.70
0.01	transition 0-5	25.37	38.62	+13.25
0.01	high 10-20	50.00	82.21	+32.21

이 표의 핵심은 SSL 의 이득이 label ratio 자체보다 SNR regime 에 더 강하게 의존한다는 점이다. Severe low-SNR(-10,-5 dB)에서는 모든 label ratio 에서 SL 과 SSL 이 거의 chance level 에 머물며, SSL gain 도 -0.38%p 에서 +0.70%p 수준으로 작다. 이는 낮은 SNR 에서 labeled sample 을 조금 늘리거나 SSL encoder 를 사용하는 것만으로는 관측 신호 안의 class-discriminative cue 가 충분히 복원되지 않음을 의미한다.

반대로 transition 영역(0-5 dB)과 high 영역(10-20 dB)에서는 SSL 의 효과가 뚜렷하다. 0-5 dB 의 transition SNR 구간에서는 일부 변조 구조가 관측 가능해지기 시작하면서 SSL 의 이점이 나타났다. 이 구간에서는 SL baseline 이 제한된 라벨만으로 안정적인 decision boundary 를 학습하기 어려운 반면, contrastive SSL 은 unlabeled samples 를 활용하여 변조별 구조를 반영하는 feature space 를 미리 형성할 수 있다. 10-20 dB 의 high-SNR 구간에서는 신호 구조가 더 명확하게 보존되므로 SSL encoder 가 학습한 representation 이 fine-tuning 과정에서 효과적으로 활용되었다. Label ratio 0.005 에서 transition gain 은 +14.55%p, high-SNR gain 은 +34.63%p 이며, 0.0025 처럼 더 적은 라벨 조건에서도 transition +14.65%p, high +49.52%p 의 큰 차이가 유지된다. 따라서 본 결과는 SSL 의 이득이 label ratio 자체보다 SNR regime 에 더 강하게 의존한다는 점을 보여준다.




그림 5. 5-20 dB 평균에서 변조 방식별 정확도.

Label ratio 0.005 기준 recoverable SNR(5-20 dB)에서 변조 방식별 성능을 보면, BPSK/QPSK와 같은 단순 변조는 상대적으로 높은 정확도를 보이고, 8PSK/16QAM/64QAM과 같은 고차 변조에서는 전반적으로 정확도가 낮아지는 경향이 나타난다. 다만 모든 변조에서 완전한 단조 감소가 나타나는 것은 아니며, 이는 constellation 형태와 제한된 labeled sample의 영향이 함께 반영된 결과로 볼 수 있다. 중요한 점은 SSL이 이러한 고차 변조의 성능 저하를 크게 완화했다는 것이다. 특히 16QAM은 SL 10.0%에서 SSL 67.0%로, 64QAM은 SL 28.7%에서 SSL 54.7%로 향상되어, SSL encoder가 저라벨 환경에서도 복잡한 변조 구조를 더 잘 보존함을 보여준다.

변조 방식별 결과에서는 한 가지 예상 밖의 패턴도 관찰된다. SL에서는 64QAM 정확도가 16QAM보다 높게 나타나는데, 이는 고차 QAM의 일반적 난이도 순서와 완전히 일치하지 않는다. 가능한 이유는 제한된 labeled dataset에서 16QAM decision boundary가 QPSK/8PSK 및 64QAM 사이에 위치하기 때문이라 생각할 수 있다. 16QAM은 amplitude level이 64QAM보다 적어 단순해 보이지만, noise와 정규화 이후에는 cluster 구조가 다른 PSK/QAM class와 겹칠 수 있고, 적은 라벨에서는 모델이 16QAM을 독립 class로 안정적으로 분리하지 못할 수 있다. 반면 64QAM은 더 넓은 amplitude 범위를 가지므로 일부 SNR에서는 amplitude cue가 남아 SL에서도 상대적으로 쉽게 맞는 sample이 생길 수 있다. 따라서 이 역전은 64QAM이 본질적으로 더 쉽다는 의미보다는, low-label sampling과 constellation overlap, 그리고 backbone의 feature bias가 함께 만든 결과로 해석하는 것이 적절하다.

4.1 Severe low-SNR 해석

-10 dB와 -5 dB의 severe low-SNR 영역에서는 대부분의 모델이 20% chance level 근처에 머물렀다. 이는 5-class classification에서 무작위 추측과 유사한 수준으로, 해당 SNR 조건에서는 잡음 전력이 신호 전력보다 크거나 유사하여 변조별 constellation 구조와 temporal I/Q pattern이 강하게 훼손되기 때문이다. Contrastive SSL은 unlabeled data로부터 유용한 representation을 학습할 수 있지만, positive pair 사이에 보존되어야 할 변조 관련 구조 자체가 잡음에 의해 충분히 관측되지 않는 경우에는 뚜렷한 성능 향상을 만들기 어렵다.

따라서 본 결과는 SSL이 low-SNR을 무조건 해결한다는 주장보다, recoverable SNR 영역에서 label-efficient representation을 제공한다는 주장에 더 적합하다.

4.2 비교군 및 추가 분석

추가 비교 실험은 다음 세 가지 방법을 같은 dense SNR test set에서 비교한 것이다.

- Low-SNR information SSL: pretraining과 fine-tuning 양쪽에 -10/-5 dB low-SNR 정보를 추가하여 학습한 조건이다. 그래프에는 low-SNR 정보를 두 단계 모두에 넣은 실험을

표시했으며, low-SNR exposure 자체가 severe 영역과 transition 영역에 어떤 영향을 주는지 확인하기 위한 ablation이다.

- Per-head SSL: 공유 SSL encoder 위에 severe, transition, high SNR regime 별 classifier head를 분리한 SNR-aware 확장 방법이다. 하나의 classifier가 모든 SNR 분포를 동시에 설명하는 대신, 각 head가 자기 SNR regime의 decision boundary를 담당한다.
- Denoising SSL: MSE reconstruction 기반 denoising pretext task를 사용한 negative baseline이다. Denoising representation이 modulation-discriminative feature로 전이되는지 확인하기 위해 포함하였다.




그림 6. Label ratio 0.005에서의 추가 방법 비교.

위 그림에서 per-head SSL은 전체 dense SNR 평균 기준으로 기본 SSL보다 +3.77%p 높았다. 개선은 모든 SNR에서 균일하게 나타나지는 않았고, 특히 0-5 dB transition 영역에서 가장 뚜렷했다. 0-5 dB 평균 gain은 +4.93%p였으며, 1 dB와 2 dB에서는 각각 +7.88%p, +7.72%p의 향상을 보였다. 이는 transition 영역에서 단일 classifier head가 low-SNR과 high-SNR의 feature distribution을 동시에 설명하기보다, 해당 SNR regime에 맞춘 head가 더 적절한 decision boundary를 학습할 수 있음을 의미한다.

반면 -10 dB와 -5 dB의 severe low-SNR 영역에서는 per-head SSL의 평균 gain이 +0.36%p에 그쳤다. Low-SNR 데이터를 head에 직접 노출하더라도 관측 I/Q에 남아 있는 modulation-discriminative information이 매우 약하면 성능을 chance level 이상으로 끌어올리기 어렵다. 따라서 per-head 구조는 severe low-SNR을 해결하는 방법이라기보다, 분류 가능한 정보가 다시 나타나기 시작하는 transition SNR에서 SSL representation을 더 잘 활용하는 방법으로 해석하는 것이 적절하다. 다음 표는 기본 SSL 대비 per-head SSL의 SNR regime 별 gain을 요약한 것이다.

표 5. 기본 SSL 대비 per-head SSL 의 SNR 영역별 평균 성능 향상.

SNR regime	SSL baseline	Per-head SSL	Gain
Severe (-10,-5)	19.78%	20.14%	+0.36%p
Transition (0-5)	39.76%	44.69%	+4.93%p
High (10-20)	77.81%	81.21%	+3.73%p
Overall	46.41%	50.19%	+3.77%p

Low-SNR information SSL 결과를 보면, -10 dB 와 -5 dB 에서는 여전히 chance level 근처에 머물렀고, 0-5 dB transition 구간에서도 기본 SSL 대비 뚜렷한 개선이 나타나지 않았다. 즉 low-SNR 정보를 pretraining 과 fine-tuning 에 모두 추가하는 것만으로는 severe low-SNR 에서 사라진 modulation-discriminative cue 를 복원하지 못했을 뿐 아니라, 경계 SNR 구간의 decision boundary 도 의미 있게 안정화하지 못한 것으로 해석된다. 따라서 이 조건은 성능 향상 방법으로 적절하지 않으며, 단순한 low-SNR exposure 는 negative ablation 으로 보는 것이 적절하다. 이 결과는 severe low-SNR 에서는 더 많은 데이터를 학습시키는 것보다 고차원적인 접근이 필요함을 보여준다.

Denoising SSL 은 본 실험에서 명확한 negative result 를 보였다. 단순 MSE reconstruction 기반 denoising pretraining 은 20 dB 에서도 약 21% 수준에 머물렀고, 전 SNR 에서 chance level 근처를 벗어나지 못했다. 이는 MSE reconstruction loss 가 waveform-level 복원 오차를 줄이는 데 초점을 두지만, 변조 분류에 필요한 class-discriminative representation 을 직접적으로 학습하도록 강제하지는 않기 때문이다. 특히 I/Q 신호에서는 sample-wise amplitude 와 phase 를 정확히 복원하는 것과 BPSK, QPSK, QAM 계열의 constellation geometry 및 decision boundary 를 구분하는 것이 동일한 목표가 아니다. 따라서 본 실험에서 사용한 단순 MSE denoising objective 는 잡음 제거형 pretext task 로는 의미가 있을 수 있으나, 저라벨 modulation classification 을 위한 표현 학습 목적과는 충분히 정렬되지 않은 것으로 해석된다.

4.3 한계 및 향후 연구

Per-head SSL 의 기대효과는 SNR 변화가 큰 환경에서 하나의 classifier 가 모든 SNR regime 을 동시에 설명해야 하는 부담을 줄이는 데 있다. 본 결과에서 severe low-SNR 은 여전히 chance level 근처에 머물렀지만, 0-5 dB transition 영역과 10-20 dB high 영역에서는 기본 SSL 보다 더 높은 정확도를 얻었다. 따라서 이 방법은 모든 SNR 에서의 문제를 해결하는 만능 구조라기보다, SNR 에 따라 feature distribution 이 달라지는 상황에서 decision boundary 를 국소적으로 조정하는 방법으로 활용할 수 있다.

향후 연구에서는 네 가지 보완이 필요하다.

첫째, 현재 실험은 synthetic-only AWGN 중심 데이터에 기반하므로, 실제 RF 수집 데이터에서 나타나는 CFO, phase offset, timing offset, multipath fading, IQ imbalance 를 포함한 조건으로 확장해야 한다.

둘째, denoising 계열 방법은 단순 MSE reconstruction 이 아니라 clean target 을 이용한 supervised denoising, denoiser 와 classifier 의 end-to-end fine-tuning, reconstruction loss 와 classification loss 를 결합한 multi-task learning, 또는 contrastive denoising objective 로 재설계할 필요가 있다.

셋째, 본 연구는 SL baseline 과 contrastive SSL pretraining 기반 fine-tuning 의 비교에 초점을 맞추었으며, SNR-conditioned classifier, per-SNR head 와 같은 다양한 self-supervised baseline 은 제한적으로만 다루었다. 따라서 본 결과는 contrastive SSL 의 SNR 별 효과를 보여주는 초기 분석으로 해석해야 하며, 향후 연구에서는 동일한 데이터 split 과 SNR sweep 조건에서 다양한 SSL 방법을 비교하여 저라벨 변조 분류에서 가장 효과적인 pretraining 전략을 분석할 필요가 있다.

넷째, 통계적 신뢰도 확보를 위해 여러 random seed 와 labeled subset 에서 반복 평가가 필요하다. 현재 결과는 제한된 seed 와 특정 labeled subset 에 기반하므로, label ratio 가 매우 작은 조건에서는 subset sampling 에 따른 variance 가 성능 해석에 영향을 줄 수 있다. 특히 label ratio 0.0025 와 0.005 와 같이 labeled sample 수가 매우 적은 경우에는 선택된 labeled subset 의 구성에 따라 fine-tuning 성능이 달라질 가능성이 있다. 향후 실험에서는 최소 3-5 개의 random seed 에 대해 mean 및 standard deviation 을 보고하여, 관찰된 SSL 성능 향상이 특정 seed 나 subset sampling 에 의한 왜곡이 아님을 검증할 필요가 있다.

표 6. 본 연구의 한계와 후속 실험 방향.

구분	현재 한계	후속 실험 방향
통계 신뢰도	단일 run 및 특정 labeled subset 중심	3-5 개 seed 에서 mean $\pm$ std 보고
채널 현실성	Synthetic AWGN SNR sweep 중심	CFO, fading, timing offset, IQ imbalance 포함
Denoising	MSE reconstruction 이 분류 표현과 불일치	clean-target denoising, multi-task loss, contrastive denoising
외부 baseline	SL/SSL/per-head/denoising 내부 ablation 중심	BYOL, SimSiam, CPC, AMC-specific SSL 과 동일 split 비교

5. 결론

본 연구는 저라벨 변조 분류 문제에서 contrastive SSL 이 SNR 조건에 따라 어떤 효과를 보이는지 분석하였다. 실험 결과, contrastive SSL 은 모든 SNR 영역에서 균일하게 성능을 향상시키지는 않았으며, severe low-SNR 영역에서는 잡음으로

인해 변조별 신호 구조가 충분히 관측되지 않아 SL 과 SSL 모두 chance level 에 가까운 성능을 보였다. 반면 0-5 dB 의 transition 구간과 10-20 dB 의 high-SNR 구간에서는 변조 구조가 점차 명확해지면서 SSL pretraining 이 적은 라벨만으로도 효과적인 representation 을 제공하였고, SL baseline 대비 향상된 분류 성능을 보였다.

추가 분석에서는 SNR-aware per-head classifier 가 기본 SSL 대비 특히 transition SNR 영역에서 성능을 개선할 수 있음을 확인하였다. 이는 하나의 classifier 가 모든 SNR 분포를 동시에 설명하는 것보다, SNR regime 별 decision boundary 를 분리하는 방식이 경계 SNR 영역에서 더 효과적일 수 있음을 시사한다. 반면 low-SNR 정보를 pretraining 과 fine-tuning 에 추가하는 것만으로는 severe low-SNR 성능을 의미 있게 개선하지 못했으며, 단순 MSE reconstruction 기반 denoising SSL 역시 modulation-discriminative representation 학습과 충분히 정렬되지 않아 chance level 근처에 머물렀다.

이러한 결과는 contrastive SSL 이 저라벨 변조 분류에서 label-efficient representation learning 방법으로 유용하지만, 그 이득은 신호 구조가 관측 가능한 SNR 영역에서 주로 나타난다는 점을 보여준다. 또한 recoverable SNR 영역에서는 SSL encoder 의 표현 학습 효과와 SNR-aware classifier 설계를 결합하는 것이 더 강건한 modulation classification 으로 이어질 가능성을 보여준다. 향후 연구에서는 CFO, timing offset, fading, IQ imbalance 와 같은 실제 RF impairments 를 포함한 환경에서의 일반화 성능을 분석하고, BYOL, SimSiam, CPC 등 다양한 SSL objective 및 SNR-aware architecture 를 동일한 조건에서 비교할 필요가 있다.

References & Repository

- [1] O'Shea and Hoydis, Deep Learning for the Physical Layer, IEEE TCCN, 2017.
- [2] Chen et al., SimCLR, ICML, 2020.
- [3] Oord et al., Contrastive Predictive Coding, 2018.
- [4] Junha Woo, "SSL Modulation Classification," GitHub repository. Available: https://github.com/jerry22926-art/SSL_modulation-classification