

Self-Supervised Modulation Classification under Varying SNR

변화하는 SNR 환경에서의 자기지도 변조 분류

Jun Ha, Woo [(School of Electrical Engineering, Korea University, Seoul, Korea), (jerry229@korea.ac.kr)]

초록

본 연구는 BPSK, QPSK, 8PSK, 16QAM, 64QAM 의 5 가지 변조 방식을 대상으로, 학습 데이터의 라벨이 매우 적은 상황에서 supervised learning(SL)과 contrastive self-supervised learning(SSL)을 비교한다. 입력은 길이 4096 의 I/Q 샘플이며, synthetic AWGN SNR sweep 에서 평가하였다. 핵심 결과는 SSL 의 이득이 모든 SNR 에서 균일하게 나타나지 않는다는 점이다. -10 dB 와 -5 dB 의 severe low-SNR 영역에서는 대부분의 모델이 20% chance level 근처에 머물렀지만, 0-5 dB 전이 구간과 10-20 dB 구간에서는 SSL 이 SL 보다 큰 폭으로 향상되었다.

Keywords: modulation classification, contrastive learning, SNR, low-label learning, synthetic I/Q

1. 서론

무선 신호의 변조 분류는 수신 I/Q 신호로부터 변조 방식을 자동 판별하는 문제이다. 실제 환경에서는 라벨이 충분한 신호 데이터를 확보하기 어렵기 때문에, 라벨 없는 신호를 이용해 encoder 를 먼저 학습하는 self-supervised learning(SSL)이 라벨 효율을 높이는 방법으로 활용될 수 있다. 그러나 SSL 의 이득이 모든 SNR 조건에서 동일하게 나타나는지는 명확하지 않다. 낮은 SNR 에서의 잡음으로 인해 변조별 I/Q 구조가 서로 겹치고, 수신 신호와 변조 라벨 사이의 구분 정보가 약해질 수 있기 때문이다.

본 연구는 contrastive SSL 이 저라벨 변조 분류에서 언제 효과적인지를 SNR regime 관점에서 분석한다. 이를 위해 5-class I/Q 변조 분류 문제에서 supervised learning(SL)과 contrastive SSL 을 동일한 backbone 과 label ratio 조건에서 비교하고, dense SNR 평가를 통해 severe low-SNR, transition SNR, high-SNR 구간별 성능 차이를 확인한다.

2. 실험 설정

항목	설정
Task	5-class modulation classification
Modulations	BPSK, QPSK, 8PSK, 16QAM, 64QAM
Input	2 x 4096 I/Q samples
Main comparison	SL baseline vs contrastive SSL pretrain + fine-tune
Low-label ratios	0.0025, 0.005, 0.01
Dense test SNR	-10, -5, 0, 1, 2, 3, 4, 5, 10, 15, 20 dB
Chance level	20%


Table 1. 전체 실험 설정 요약.

데이터는 synthetic I/Q 기반이며, 현재 결과는 AWGN channel 중심의 SNR 변화에 초점을 둔다. Channel decoding, encoding 이나 CFO, timing offset, fading, IQ imbalance 의 영향을 받는 실제 RF 환경 일반화는 본 실험 환경에서 배제하였다.

3. 모델 구조와 학습 방법

SL 과 SSL fine-tuning 은 같은 residual 1D CNN backbone 을 공유한다. Backbone 은 4 개의 residual block 으로 구성되며 채널 수는 2->64->128->256->512 로 증가한다. 각 block 은 Conv1d(kernel=3, padding=1), BatchNorm, ReLU, Conv1d, BatchNorm 과 shortcut connection 을 사용한다. 각 block 뒤에는 MaxPool1d(2)가 적용되어 길이 4096 입력은 최종적으로 길이 256 의 feature map 이 된다. 최종 feature dimension 은 512 x 256 이다. 입력은 시간축 표준편차로 나누어 scale 을 정규화한다.


A. SimCLR-style SSL Pretraining



Positive pair: two augmented views of the same signal
Temperature $\tau = 0.5$

Fig. 1. SimCLR-style SSL pretraining pipeline.


B. Shared 1D ResNet Encoder



The same encoder is used for SL, SSL fine-tuning, and SNR-regime per-head classification.

Fig. 2. Shared 1D ResNet encoder architecture.

C. Fine-tuning and SNR-aware Heads



Per-head SSL keeps one shared encoder but uses different classification heads for different SNR regimes.

Fig. 3. Fine-tuning and SNR-aware per-head classifier.

구성 요소	구현 세부
Encoder	4 residual Conv1d blocks, channels 2/64/128/256/512, MaxPool after each block
Projection head	Linear(512*256 -> 512), ReLU, Linear(512 -> 128)
SSL classifier	pretrained encoder feature + Dropout(0.5) + Linear(512*256 -> 5)
SL classifier	same backbone trained from scratch + Linear(512*256 -> 5)
Pretrain optimizer	Adam, lr=5e-4, batch size=16, 100 epochs
Fine-tune optimizer	Adam, encoder lr=1e-5, classifier lr=2e-4, weight decay=1e-4, batch size=16, 200 epochs

Table 2. SL/SSL backbone 및 fine-tuning 구성.

4. Contrastive objective 와 augmentation

SSL pretraining 은 SimCLR-style NT-Xent loss 를 사용한다. 같은 원본 신호에서 독립적으로 augmentation 한 두 view 를 positive pair 로 두고, batch 내 다른 sample 의 view 를 negative 로 사용한다. Projection vector z 는 L2 normalization 후 similarity 계산에 사용된다.

$$\mathcal{L}_i = -\log \frac{\exp(\text{sim}(z_i, z_j)/\tau)}{\sum_{k \neq i} \exp(\text{sim}(z_i, z_k)/\tau)}, \quad \tau = 0.5$$

여기서 z_i 와 z_j 는 같은 원본 신호에서 생성된 두 augmented view 의 projection 이고, $\text{sim}(\cdot, \cdot)$ 은 cosine similarity 이다. 분모는 anchor i 를 제외한 batch 내 다른 view 들을 negative 로 포함하며, temperature τ 는 0.5 로 설정하였다.

Augmentation	세부값
Amplitude scaling	$p=0.8$, scale $\sim \text{Uniform}(0.5, 1.5)$
Phase rotation	$p=0.6$, angle $\sim \text{Uniform}(0, 2\pi)$
AWGN perturbation	$p=0.8$, additive noise sigma=0.01
Fine-tune scaling	$p=0.5$, scale $\sim \text{Uniform}(0.95, 1.05)$
Fine-tune AWGN	$p=0.5$, additive noise sigma=0.001

Table 3. Contrastive pretraining 과 fine-tuning augmentation 설정.

주의할 점은 phase rotation 증강이 과하면 역효과를 불러올 수 있다는 것이다. 이는 carrier phase 변화에 대한 불변성을 학습시키는 장점이 있지만, PSK/QAM 계열에서 위상 구조가 변조 식별에 중요한 경우 모델이 배울 위상 정보를 약화시킬 가능성도 있다. 따라서 severe low-SNR 에서 noise 와 augmentation 이 함께 구분 정보를 흐리는 문제가 발생할 수 있다.

5. 결과




Fig. 4. label ratio 0.005 에서 dense SNR 평가.

ratio	SNR 영역	SL	SSL	Gain
0.0025	severe -10,-5	20.02	19.64	-0.38
0.0025	transition 0-5	20.25	34.91	+14.65
0.0025	high 10-20	28.67	78.19	+49.52
0.005	severe -10,-5	20.06	19.78	-0.28
0.005	transition 0-5	25.21	39.76	+14.55
0.005	high 10-20	42.85	77.48	+34.63
0.01	severe -10,-5	19.64	20.34	+0.70
0.01	transition 0-5	25.37	38.62	+13.25
0.01	high 10-20	50.00	82.21	+32.21

Table 4. Label ratio 와 SNR 영역별 SL/SSL 평균 정확도 및 gain.

이 표의 핵심은 SSL 의 이득이 label ratio 자체보다 SNR regime 에 더 강하게 의존한다는 점이다. severe low-SNR(-10,-5 dB)에서는 모든 label ratio 에서 SL 과 SSL 이 거의 chance level 에 머물며, SSL gain 도 -0.38%p 에서 +0.70%p 수준으로 작다. 이는 낮은 SNR 에서 labeled sample 을 조금 늘리거나 SSL encoder 를 사용하는 것만으로는 관측 신호 안의 class-discriminative cue 가 충분히 복원되지 않음을 의미한다.

반대로 transition 영역(0-5 dB)과 high 영역(10-20 dB)에서는 SSL 의 효과가 뚜렷하다. label ratio 0.005 에서 transition gain 은 +14.55%p, high-SNR gain 은 +34.63%p 이며, 0.0025 처럼 더 적은 라벨 조건에서도 transition +14.65%p, high +49.52%p 의 큰 차이가 유지된다. 따라서 본 결과는 SSL 이 severe low-SNR 을 직접 해결한다기보다, 정보가 남아 있는 SNR 구간에서 적은 라벨로도 안정적인 representation 을 제공한다는 해석을 지지한다.




Fig. 5. 5-20 dB 평균에서 변조 방식별 정확도.

label ratio 0.005 기준 recoverable SNR(5-20 dB)에서 변조 방식별 성능을 보면, BPSK/QPSK 와 같은 단순 변조는 상대적으로 높은 정확도를 보이고, 8PSK/16QAM/64QAM 과 같은 고차 변조에서는 전반적으로 정확도가 낮아지는 경향이 나타난다. 다만 모든 변조에서 완전한 단조 감소가 나타나는 것은 아니며, 이는 constellation 형태와 제한된 labeled sample 의 영향이 함께 반영된 결과로 볼 수 있다. 중요한 점은 SSL 이 이러한 고차 변조의 성능 저하를 크게 완화했다는 것이다. 특히 16QAM 은 SL 10.0%에서 SSL

67.0%로, 64QAM 은 SL 28.7%에서 SSL 54.7%로 향상되어, SSL encoder 가 저라벨 환경에서도 복잡한 변조 구조를 더 잘 보존함을 보여준다.

변조 방식별 결과에서는 한 가지 예상 밖의 패턴도 관찰된다. SL 에서는 64QAM 정확도가 16QAM 보다 높게 나타나는데, 이는 고차 QAM 의 일반적 난이도 순서와 완전히 일치하지 않는다. 가능한 이유는 제한된 labeled subset 에서 16QAM decision boundary 가 QPSK/8PSK 및 64QAM 사이에 위치기 때문이라 생각할 수 있다. 16QAM 은 amplitude level 이 64QAM 보다 적어 단순해 보이지만, noise 와 정규화 이후에는 cluster 구조가 다른 PSK/QAM class 와 겹칠 수 있고, 적은 라벨에서는 모델이 16QAM 을 독립 class 로 안정적으로 분리하지 못할 수 있다. 반면 64QAM 은 더 넓은 amplitude spread 를 가지므로 일부 SNR 에서는 amplitude cue 가 남아 SL 에서도 상대적으로 쉽게 맞는 sample 이 생길 수 있다. 따라서 이 역전은 64QAM 이 본질적으로 더 쉽다는 의미보다는, low-label sampling 과 constellation overlap, 그리고 backbone 의 feature bias 가 함께 만든 결과로 해석하는 것이 적절하다.

6. Severe low-SNR 해석

severe low-SNR 에서 성능이 chance level 에 머무는 현상은 단순히 학습 데이터 부족으로만 설명하기 어렵다. 첫째, 모델이 학습할 정보의 관점에서 SNR 이 낮아질수록 관측 I/Q 와 modulation label 사이의 정보량이 감소한다. 둘째, constellation overlap 이 커지면 16QAM 과 64QAM 처럼 진폭, 위상 구조가 복잡한 class 는 decision boundary 가 흐려진다. 셋째, contrastive augmentation 이 너무 강하면 positive pair 를 맞추는 과정에서 분류에 필요한 세밀한 phase, amplitude cue 가 feature space 에서 약화될 수 있다. 따라서 본 결과는 SSL 이 low-SNR 을 무조건 해결한다는 주장보다, recoverable SNR 영역에서 label-efficient representation 을 제공한다는 주장에 더 적합하다.

7. 제안 방법 확장 및 추가 분석

추가 비교 실험은 다음 세가지 방법을 같은 dense SNR test set 에서 비교한 것이다.

- Low-SNR information SSL: pretraining 과 fine-tuning 양쪽에 -10/-5 dB low-SNR 정보를 추가하여 학습한 조건이다. 그래프에는 low-SNR 정보를 두 단계 모두에 넣은 실험을 표시했으며, low-SNR exposure 자체가 severe 영역과 transition 영역에 어떤 영향을 주는지 확인하기 위한 ablation 이다.
- Per-head SSL: 공유 SSL encoder 위에 severe, transition, high SNR regime 별 classifier head 를 분리한 SNR-aware 확장 방법이다. 하나의 classifier 가 모든 SNR 분포를 동시에 설명하는 대신, 각 head 가 자기 SNR regime 의 decision boundary 를 담당한다.
- Denoising SSL: MSE reconstruction 기반 denoising pretext task 를 사용한 negative baseline 이다. 잡음 제거형

representation 이 modulation-discriminative feature 로 전이되는지 확인하기 위해 포함하였다.




Fig. 6. label ratio 0.005 에서 추가 방법 비교.

위 그림에서 per-head SSL 은 전체 dense SNR 평균 기준으로 기본 SSL 보다 +3.77%p 높았다. 개선은 모든 SNR 에서 균일하게 나타나지는 않았고, 특히 0-5 dB transition 영역에서 가장 뚜렷했다. 0-5 dB 평균 gain 은 +4.93%p 였으며, 1 dB 와 2 dB 에서는 각각 +7.88%p, +7.72%p 의 향상을 보였다. 이는 transition 영역에서 단일 classifier head 가 low-SNR 과 high-SNR 의 feature distribution 을 동시에 설명하기보다, 해당 SNR regime 에 맞춘 head 가 더 적절한 decision boundary 를 학습할 수 있음을 의미한다.

반면 -10 dB 와 -5 dB 의 severe low-SNR 영역에서는 per-head SSL 의 평균 gain 이 +0.36%p 에 그쳤다. low-SNR 데이터들 head 에 직접 노출하더라도 관측 I/Q 에 남아 있는 modulation-discriminative information 이 매우 약하면 성능을 chance level 이상으로 끌어올리기 어렵다. 따라서 per-head 구조는 severe low-SNR 을 해결하는 방법이라기보다, 분류 가능한 정보가 다시 나타나기 시작하는 transition SNR 에서 SSL representation 을 더 잘 활용하는 방법으로 해석하는 것이 적절하다. 다음 표는 기본 SSL 대비 per-head SSL 의 SNR regime 별 gain 을 요약한 것이다.

SNR regime	SSL baseline	Per-head SSL	Gain
Severe (-10,-5)	19.78%	20.14%	+0.36%p
Transition (0-5)	39.76%	44.69%	+4.93%p
High (10-20)	77.81%	81.21%	+3.73%p
Overall	46.41%	50.19%	+3.77%p

Table 5. 기본 SSL 대비 per-head SSL 의 SNR regime 별 평균 정확도 및 gain.

Low-SNR information SSL 결과를 보면, -10 dB 와 -5 dB 에서는 여전히 chance level 근처에 머물렀고, 0-5 dB transition 구간에서도 기본 SSL 대비 뚜렷한 개선이 나타나지 않았다. 즉 low-SNR 정보를 pretraining 과 fine-tuning 에 모두 추가하는

것만으로는 severe low-SNR 에서 사라진 modulation-discriminative cue 를 복원하지 못했을 뿐 아니라, 경계 SNR 구간의 decision boundary 도 의미 있게 안정화하지 못한 것으로 해석된다. 따라서 이 조건은 성능 향상 방법으로 적절하지 않으며, 단순한 low-SNR exposure 은 negative ablation 으로 보는 것이 적절하다. 이 결과는 severe low-SNR 에서는 더 많은 데이터를 학습시키는 것보다 고차원적인 접근이 필요함을 보여준다.

Denoising SSL 은 본 실험에서 명확한 negative result 를 보였다. 단순 MSE reconstruction 기반 denoising pretraining 은 20 dB 에서도 약 21% 수준에 머물렀고, 전 SNR 에서 chance level 근처를 벗어나지 못했다. 이는 waveform reconstruction loss 가 modulation classification 에 필요한 class-discriminative feature 를 효과적으로 학습하지 못함을 보여준다. 즉 본 실험에서 사용한 MSE denoising objective 가 이 과제에 적합한 task 가 아니었다고 해석하는 것이 타당하다.

8. 기대효과, 한계 및 향후 연구

Per-head SSL 의 기대효과는 SNR 변화가 큰 환경에서 하나의 classifier 가 모든 SNR regime 을 동시에 설명해야 하는 부담을 줄이는 데 있다. 본 결과에서 severe low-SNR 은 여전히 chance level 근처에 머물렀지만, 0-5 dB transition 영역과 10-20 dB high 영역에서는 기본 SSL 보다 더 높은 정확도를 얻었다. 따라서 이 방법은 모든 SNR 에서의 문제를 해결하는 만능 구조라기보다, SNR 에 따라 feature distribution 이 달라지는 상황에서 recoverable 영역의 decision boundary 를 국소적으로 조정하는 방법으로 활용할 수 있다.

향후 연구에서는 네 가지 보완이 필요하다.

첫째, 현재 실험은 synthetic-only AWGN 중심 데이터에 기반하므로, 실제 RF 수집 데이터에서 나타나는 CFO, phase offset, timing offset, multipath fading, IQ imbalance 를 포함한 조건으로 확장해야 한다.

둘째, denoising 계열 방법은 단순 MSE reconstruction 이 아니라 clean target 을 이용한 supervised denoising, denoiser 와 classifier 의 end-to-end fine-tuning, reconstruction loss 와 classification loss 를 결합한 multi-task learning, 또는 contrastive denoising objective 로 재설계할 필요가 있다.

셋째, 본 프로젝트의 비교군은 SL, contrastive SSL, SNR-conditioned/per-head head, MSE denoising SSL 에 제한되어 있으므로, BYOL/SimSiam 과 같은 negative-free SSL, CPC 기반 temporal prediction, RF/AMC 전용 self-supervised baseline 을 동일한 데이터 split 과 SNR sweep 에서 추가 비교해야 한다.

넷째, 현재 결과는 주로 단일 seed 와 특정 labeled subset 에 기반하므로, 최소 3-5 개 seed 에 대해 mean $\pm$ std 를 보고하여 per-head gain 이 sampling artifact 가 아님을 확인해야 한다.

통계적 신뢰도 측면에서는 현재 결과가 주로 단일 run 과 특정 labeled subset 에 기반한다는 한계가 있다. SSL fine-tuning 은 seed, labeled subset sampling, augmentation randomness 에 민감할 수

있으므로, 후속 실험에서는 최소 3-5 개 seed 에 대해 mean $\pm$ std 를 보고해야 한다. 특히 label ratio 0.0025 와 0.005 처럼 labeled sample 수가 매우 적은 조건에서는 subset variance 가 결과 해석에 큰 영향을 줄 수 있다.

구분	현재 한계	후속 실험 방향
통계 신뢰도	단일 run 및 특정 labeled subset 중심	3-5 개 seed 에서 mean $\pm$ std 보고
채널 현실성	Synthetic AWGN SNR sweep 중심	CFO, fading, timing offset, IQ imbalance 포함
Denoising	MSE reconstruction 이 분류 표현과 불일치	clean-target denoising, multi-task loss, contrastive denoising
외부 baseline	SL/SSL/per-head/denoising 내부 ablation 중심	BYOL, SimSiam, CPC, AMC-specific SSL 과 동일 split 비교

Table 6. 본 연구의 한계와 후속 실험 방향.

9. 결론

본 연구는 contrastive SSL 이 라벨 효율을 크게 높일 수 있음을 보였지만, 그 효과는 SNR regime 에 따라 달라졌다. severe low-SNR 에서는 정보량 감소와 constellation overlap, augmentation 에 의한 phase, amplitude cue 약화가 함께 작용할 수 있다. 반면 1-5 dB 의 transition 구간과 10-20 dB 의 high SNR 구간에서는 SSL encoder 가 적은 라벨만으로도 변조 구조를 더 잘 보존하며 SL 대비 뚜렷한 성능 향상을 보였다. 추가로 SNR regime 별 per-head classifier 를 도입하면 transition 구간에서 기본 SSL 보다 더 높은 성능을 얻을 수 있어, SNR-aware classifier specialization 이 본 연구의 유망한 확장 방향임을 확인하였다. 이러한 결과는 contrastive SSL 을 모든 SNR 을 해결하는 단일 해법으로 보기보다, recoverable SNR 영역에서 label-efficient feature extraction 을 제공하고 SNR-aware head 설계와 결합될 때 더 효과적인 방법으로 해석해야 함을 보여준다.

References & Repository

[1] O'Shea and Hoydis, Deep Learning for the Physical Layer, IEEE TCCN, 2017.

[2] Chen et al., SimCLR, ICML, 2020.

[3] Oord et al., Contrastive Predictive Coding, 2018.

[4] Oord et al., Contrastive Predictive Coding, 2018.

[5] Junha Woo, "SSL Modulation Classification," GitHub repository. Available: https://github.com/jerry22926-art/SSL_modulation-classification